

Построение Legal RAG: вклад компонентов в качество ответов и цитирования

1. Гипотеза

Юридическая RAG-система должна прочитать документы, найти сведения для ответа и указать подтверждающие страницы. Ошибка на любом этапе может привести к неверному выводу или неполной ссылке. Цель исследования - построить Legal RAG и экспериментально обосновать выбор его компонентов.

Retrieval-Augmented Generation (RAG) объединяет поиск внешних сведений с генерацией текста [1]. LegalBench-RAG оценивает поиск фрагментов юридических документов [2], а ALCE разделяет оценку ответов и цитирования [3]. В этой работе исследуется, как последовательное добавление компонентов одной системы меняет обе характеристики на фиксированном корпусе. Исследовательский вопрос: **как построить Legal RAG, который даёт качественные ответы и полные, точные ссылки на источники?**

Предполагается, что полный пайплайн превосходит простой RAG baseline. Вклад отдельных решений проверяется шестью гипотезами:

- **H1:** OCR повышает качество ответов и полноту ссылок при работе со сканами.
- **H2:** фрагменты разных масштабов повышают качество ответов и полноту ссылок относительно фиксированного размера.
- **H3:** добавление лексического поиска к семантическому повышает качество ответов и полноту ссылок.
- **H4:** повторное ранжирование найденных фрагментов повышает качество ответов.
- **H5:** дополнительная обработка по типу ответа повышает средний балл структурированных ответов.
- **H6:** отдельный выбор страниц для цитирования повышает точность ссылок; влияние на полноту проверяется экспериментально.

2. Методология

Данные и дизайн эксперимента. Использован набор, ранее применявшийся при разработке Legal RAG: 30 юридических PDF DIFC, 590 страниц и 100 вопросов с эталонными ответами. Из них 70 требуют структурированного ответа - например, числа, даты или имени, - а 30 допускают свободный текст. Для 95 вопросов размечены страницы-источники. Созданы две версии корпуса: исходная и смешанная. В последней 10 случайно выбранных документов, содержащих 107 страниц, заменены изображениями страниц при 300 DPI без текстового слоя; seed выбора - 20260920. Преобразование затронуло источники 52 вопросов. Содержание, идентификаторы и номера страниц сохранены, исходный текст сканов исключён из индекса варианта без OCR.

Пайплайн и сравнения. Baseline R0 извлекает текст PDF, разбивает его на фрагменты по 300 токенов с перекрытием 50, выполняет семантический поиск и генерирует ответ. Ссылки включают все страницы переданного контекста. Далее последовательно добавляются OCR (R1), представления страниц, разделов, пунктов, микрофрагментов и таблиц (R2), лексический поиск с объединением результатов (R3), reranker (R4), обработка ответа (R5) и выбор цитируемых страниц (R6). Каждый вариант сравнивается с предыдущим. Основная цепочка выполняется на смешанном корпусе; R0 и R1 дополнительно проверяются на исходном. Всего исследованы девять условий.

Для OCR используется PP-OCRv5, для семантического поиска - Qwen3-Embedding-0.6B, для повторного ранжирования - Qwen3-Reranker-0.6B. Из 24 кандидатов формируется контекст не более 2400 токенов и восьми фрагментов. Модель генерации фиксирована: GPT-5.4-mini, snapshot 2026-03-17, reasoning high. Типизированная схема генерации одинакова во всех вариантах; R5 добавляет нормализацию, пороги уверенности и валидацию. R6 использует указания модели на поддерживающие фрагменты для сужения ссылок. R4-R6 получают одинаковый контекст и переиспользуют один ответ генератора. R6 включает все исследуемые блоки, но не все эвристики исходной реализации.

Оценка. Качество ответа вычисляется как $Q = 0,7 \times \text{средний балл структурированных ответов} + 0,3 \times \text{средний балл свободных ответов}$. Структурированные ответы оцениваются исходными правилами сравнения с эталоном. Свободные ответы оценивает та же модель по пяти критериям 0/1: правильность, полнота, опора на контекст, калибровка уверенности, ясность и релевантность; баллы усредняются. Оценщик получает эталон и контекст, но не название конфигурации. Precision - доля эталонных страниц среди выданных, recall - доля выданных эталонных страниц среди всех требуемых. Метрики ссылок усредняются по 95 вопросам; пустой ответ по ссылкам при непустом эталоне получает нули. Q является агрегированным баллом, а не долей полностью правильных ответов. Сравниваются средние метрики одного прогона; статистическая значимость и вариативность повторных запусков не оценивались.

3. Результаты

Последовательное включение компонентов. Полный пайплайн превосходит baseline по всем трём метрикам, однако улучшение не является монотонным (таблица 1). От R0 к R6 Q увеличивается на 38,20 процентного пункта, precision - на 54,16, recall - на 36,23.

Таблица 1. Итоговые метрики на смешанном корпусе, %. Каждый вариант наследует предыдущий. Q: 100 вопросов; precision и recall: 95 вопросов.

Вариант	Добавление	Q	Precision	Recall
R0	Baseline	46,20	7,60	38,51
R1	OCR	63,20	11,22	61,62
R2	Фрагменты разных масштабов	49,80	14,73	52,89
R3	Лексический поиск	74,60	22,19	72,68
R4	Повторное ранжирование	84,40	27,08	78,95
R5	Обработка по типу ответа	84,40	27,08	78,95
R6	Выбор цитируемых страниц	84,40	61,77	74,74

Доступность текста. На исходных PDF Q baseline составляет 65,40%. После замены части документов сканами он снижается до 46,20%, а включение OCR восстанавливает его до 63,20%. Recall соответственно меняется с 62,15% до 38,51% и затем до 61,62%. На исходном корпусе R0 и R1 дают одинаковые результаты. Таким образом, H1 поддерживается: OCR восстанавливает большую часть потери качества, вызванной недоступностью текстового слоя.

Поиск и подготовка ответа. Добавление разных масштабов фрагментов повышает precision, но снижает Q на 13,40 п.п. и recall на 8,73 п.п.; H2 не поддерживается. В одном из вопросов о деле SCT 295/2025 R2 теряет эталонную страницу и называет истца другого дела. Лексический поиск возвращает нужный документ и правильный ответ. На всём наборе переход R2 → R3 повышает Q на 24,80 п.п., а recall на 19,78 п.п. Reranker дополнительно повышает Q на 9,80 п.п. Эти результаты поддерживают H3 и H4. Дополнительная обработка R5 не меняет ответы: средний балл структурированных ответов остаётся 88,57%, поэтому H5 не поддерживается.

Цитирование. В R6 precision повышается с 27,08% до 61,77% при неизменном Q, но recall снижается с 78,95% до 74,74%. Набор ссылок сокращается в 65 вопросах; в пяти из них удаляются и эталонные страницы. H6 поддерживается по точности, одновременно выявляя компромисс: более узкий набор цитат может потерять часть необходимых оснований.

Вывод. Построенный Legal RAG превзошёл простой baseline по качеству ответов, точности и полноте ссылок. Последовательное сравнение показало, как разные этапы обеспечивают этот результат: OCR восстанавливает доступ к содержанию сканов, гибридный поиск и повторное ранжирование повышают качество ответов, а отдельный выбор цитат повышает точность ссылок. При этом максимальная полнота ссылок достигается до их дополнительного отбора. Следовательно, при построении Legal RAG необходимо отдельно оценивать качество ответа и цитирование: улучшение одного показателя не гарантирует улучшения остальных. Эксперимент обосновывает вклад этих компонентов и позволяет выбирать между более точным и более полным набором ссылок в зависимости от требований задачи.

Литература

- [1] Lewis P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS, 2020. [arXiv:2005.11401](https://arxiv.org/abs/2005.11401).
- [2] Pipitone N., Alami G. H. *LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain*. 2024. [arXiv:2408.10343](https://arxiv.org/abs/2408.10343).
- [3] Gao T., Yen H., Yu J., Chen D. *Enabling Large Language Models to Generate Text with Citations*. EMNLP, 2023, pp. 6465-6488. [doi:10.18653/v1/2023.emnlp-main.398](https://doi.org/10.18653/v1/2023.emnlp-main.398).

Материалы исследования: исходная система, экспериментальная реализация и протокол, метрики и оценки по вопросам.